

Calcular el pagerank de una matriz dispersa

El **objetivo de esta práctica** es codificar la función $[x, precision1] = \text{calculo_PR}(A, tol, n_iter, x0)$ para calcular el pagerank de la matriz G, y medir las prestaciones numéricas de dicha función.

Se quiere calcular el pagerank de una matriz G, pero como G es una matriz densa y de gran tamaño, por tanto no podemos almacenarla en memoria.

Utilizamos la siguiente estrategia:

“Codificar la función

$$[x, precision1] = \text{calculo_PR}(A, tol, n_iter, x0)$$

que partiendo de la matriz A (dispersa), utiliza el método de la potencia para calcular x el pagerank de G”.

Siguiendo la notación de clase:

- C la matriz de conectividad, $N = \text{size}(C, 1)$;
- $Nj = \text{sum}(C)$, vector de número de links de salida,
- A es la matriz C reescalada por columnas:
 $A(:, k) = 0$ si $Nj(k) = 0$ (la columna k de las matrices A y C son nulas).
 $A(:, k) = C(:, k) / Nj(k)$ si $Nj(k) \neq 0$
- El vector dj es el complementario del vector Nj ($dj = 1 - Nj$).
 $dj(k) = 1$ si $Nj(k) = 0$
 $dj(k) = 0$ si $Nj(k) \neq 0$
- El vector fila $e = \text{ones}(1, N)$;
- La matriz G tiene la siguiente expresión:

$$G = \alpha S + (1 - \alpha) E = \alpha A + \frac{1}{n} e^T [\alpha dj + (1 - \alpha) e], \quad \alpha = 0.85$$

A. Rutina auxiliar

1. Matrices dispersas (mdis_A)

Codificar la rutina

$$A = \text{mdis_A}(N)$$

Tiene como variable de entrada la dimensión N, y como variable de salida una matriz dispersa aleatoria A de tamaño NxN, cuyas columnas sumen 1 o 0. Utilizar la siguiente plantilla:

```
function A=mdis_A(N)
R=5; % R=número de links entrada/salida de cada nodo
p=randi(N,1,R*N); q=randi(N,1,R*N);
A=sparse(p,q,1,N,N);
Nj=sum(A);
    % Reescalar las columnas de A:
    % A(:,k)=0 si Nj(k)=0
    % A(:,k)=A(:,k)/Nj(k) si Nj(k) ~= 0
return
```

B. Función calculo_PR

Modificar el método de la potencia para obtener la función

$$[x, precision1] = \text{calculo_PR}(A, tol, n_iter, x0)$$

que calcula x el pagerank de la matriz densa G, utilizando como variable de entrada la matriz dispersa A.

El método de la potencia aplicado a la matriz G se puede escribir como el siguiente método iterativo:

$$\begin{cases} k = 0, 1, \dots \\ x^k = x^k / \text{norm}(x^k) \\ x^{k+1} = \alpha A x^k + \frac{1}{n} e^T [\alpha \text{dj} + (1 - \alpha) e] x^k \end{cases}$$

Para implementar este método utilizamos la siguiente **estrategia numérica**:

En el cálculo de $x^{k+1} = \alpha A x^k + \frac{1}{n} e^T [\alpha \text{dj} + (1 - \alpha) e] x^k$ tenemos dos sumandos: el primer sumando es una matriz dispersa mientras que el segundo sumando es una matriz densa.

Para evitar calcular $e^T [\alpha \text{dj} + (1 - \alpha) e]$ que es una matriz densa, calculamos:

- el vector fila $v = [\alpha \text{dj} + (1 - \alpha) e]$ es constante en todo el proceso iterativo, y lo calculamos una sola vez antes de iniciar el bucle for/while,
- en cada iteración: calcular primero el escalar $v x^k$, y después calcular el vector columna $\frac{1}{n} e^T v x^k$.

Como se puede observar, el orden de los factores puede ahorrar mucha memoria.

Otras especificaciones para codificar el código:

- Las variables de entrada tol, n_iter y x0 son las mismas que en el método de la potencia.
- Las variables de salida son:
El vector x es el pagerank de G, esto es, $Gx=x$ y $\text{sum}(x)=1$.
La variable de salida precision1 = norm($Gx-x$,1), norma 1 del vector $Gx-x$.

Nota: No disponemos de la matriz G explícitamente.

Ejecutar la función **calculo_PR(A)** para matrices A generadas con la función **A=mdis_A(N)**, para los valores de N=10², 10³, 10⁴, 10⁵,.... Completar la siguiente tabla

	Tiempo [seg]	Memoria [MB]	Precisión $\ Gx - x\ _1$
N=			
N=			

Comentar los resultados numéricos obtenidos.